

ANKARA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



BLM4522

AĞ TABANLI PARALEL DAĞITIM SİSTEMLERİ

PROJE 5

VERİ TEMİZLEME VE ETL SÜREÇLERİ TASARIMI

Zeliha Kıyak

22290878

 **GitHub** : <https://github.com/zelihakiyak>

VIDEO LİNKİ: <https://youtu.be/T7anlyDTjmo>

1. Giriş

Bu projede iki farklı kaynak veritabanından (Northwind ve AdventureWorks2022) veri çekilerek ETL (Extract, Transform, Load) süreci tasarlanmış ve uygulanmıştır. Proje kapsamında ham veriler staging tablosuna alınmış, veri kalitesi analizi yapılmış, temizleme ve dönüştürme işlemleri gerçekleştirilmiş ve temizlenen veriler hedef tabloya yüklenmiştir.

2. ETL Mimarisi

ETL süreci üç aşamadan oluşmaktadır. Extract aşamasında iki farklı kaynaktan veri çekilmiştir. Transform aşamasında veriler temizlenmiş ve standartlaştırılmıştır. Load aşamasında temizlenen veriler hedef tabloya aktarılmıştır.

Aşama	İşlem	Tablo
Extract	Northwind ve AdventureWorks'ten veri çekme	dbo.STG_Musteri
Transform	Temizleme, format düzeltme, kalite skoru	dbo.TEM_Musteri
Load	Temizlenen veriyi hedefe yükleme	dbo.Hedef_Musteri

3. Extract - Veri Çıkarma

İki farklı kaynaktan veri incelenerek staging tablosuna aktarıldı. Northwind veritabanından müşteri adı, şehir, ülke ve telefon bilgileri; AdventureWorks2022'den kişi adı ve email bilgileri çekildi.

Kaynak	Tablo	Çekilen Kolonlar	Kayıt Sayısı
Northwind	dbo.Customers	ContactName, City, Country, Phone	91
AdventureWorks	Person.Person + Person.EmailAddress	FirstName, LastName, EmailAddress	753
TOPLAM	-	-	844

```
-- Northwind'den veri çek
INSERT INTO dbo.STG_Musteri
(KaynakSistem, KaynakID, AdSoyad, Sehir, Ulke, Telefon, Email)
SELECT 'Northwind', CustomerID, ContactName,
      City, Country, Phone, NULL
FROM Northwind.dbo.Customers;
```

```
-- AdventureWorks'ten veri çek
INSERT INTO dbo.STG_Musteri
(KaynakSistem, KaynakID, AdSoyad, Sehir, Ulke, Telefon, Email)
SELECT 'AdventureWorks',
      CAST(p.BusinessEntityID AS NVARCHAR(50)),
      p.FirstName + ' ' + p.LastName,
      NULL, NULL, NULL, e.EmailAddress
```

```
FROM Person.Person p
JOIN Person.EmailAddress e ON p.BusinessEntityID =
e.BusinessEntityID
WHERE p.PersonType = 'SC';
```

4. Veri Kalitesi Analizi

Staging tablosuna yüklenen ham veri üzerinde kapsamlı kalite analizi yapılmıştır. NULL değerler, boş stringler, geçersiz email formatları ve tutarsız telefon formatları incelenmiştir.

Kolon	NULL Sayısı	Açıklama
AdSoyad	0	Tüm kayıtlarda mevcut
Sehir	753	AdventureWorks kaynağında bu alan yok
Ulke	753	AdventureWorks kaynağında bu alan yok
Telefon	753	AdventureWorks kaynağında bu alan yok
Email	91	Northwind kaynağında bu alan yok

Geçersiz email analizi sonucunda 0 geçersiz email tespit edildi. Telefon alanında ise çok farklı formatlar gözlemlendi: (171) 555-7788, 030-0074321, (5) 555-4729 gibi tutarsız yapılar.

21 farklı ülke verisi tespit edildi. Ülke isimleri tutarlı büyük harfle yazılmıştı (Germany, France, USA vb.) ancak AdSoyad kolonunda büyük/küçük harf tutarsızlıkları mevcuttu.

5. Transform - Veri Dönüştürme ve Temizleme

Ham veriler üç temel temizleme işleminden geçirilmiştir: NULL değerlerin 'Bilinmiyor' ile doldurulması, AdSoyad kolonunun Title Case formatına dönüştürülmesi ve veri kalitesi skorunun atanması.

Temizleme İşlemi	Yöntem	Etkilenen Kayıt
NULL Sehir/Ulke/Telefon	ISNULL() ile 'Bilinmiyor' atandı	753 kayıt
NULL Email	ISNULL() ile 'Bilinmiyor' atandı	91 kayıt
AdSoyad fazla boşluk	TRIM() ile temizlendi	Tüm kayıtlar
AdSoyad büyük/küçük harf	STRING_SPLIT + STRING_AGG ile Title Case	753 kayıt
Veri kalitesi skoru	TAM / KISMI / EKSİK kategorisi atandı	844 kayıt

```
-- Title Case düzeltmesi
UPDATE dbo.TEM_Musteri
SET AdSoyad = (
    SELECT STRING_AGG(
```

```

        UPPER(LEFT(value, 1)) + LOWER(SUBSTRING(value, 2,
        LEN(value))),
        ' '
    )
    FROM STRING_SPLIT(AdSoyad, ' ')
    WHERE value != ''
)
WHERE KaynakSistem = 'AdventureWorks';
-- ÖNCE: gustavo achong → SONRA: Gustavo Achong

```

Veri kalitesi skoru hesaplaması:

Skor	Kriter	Adet
TAM	Şehir + Telefon + Email hepsi mevcut	0
KISMI	En az bir alan eksik	844
EKSIK	Tüm alanlar eksik	0

Tüm kayıtların KISMI çıkması beklenen bir sonuçtur. İki kaynak birbirini tamamlamaktadır ancak tek başına hiçbirisi tam veri sağlayamamaktadır. Bu durum, veri entegrasyonunun önemini açıkça göstermektedir.

6. Load - Veri Yükleme

Temizlenen ve dönüştürülen veriler dbo.Hedef_Musteri tablosuna yüklendi. Yükleme sonrası doğrulama sorguları çalıştırılarak verinin bütünlüğü kontrol edildi.

Kaynak	Toplam	Email Var	Şehir Var	Telefon Var
Northwind	91	0	91	91
AdventureWorks	753	753	0	0
TOPLAM	844	753	91	91

Northwind 91 müşteri kaydı için şehir, ülke ve telefon bilgisi sağlarken AdventureWorks 753 kişi kaydı için email bilgisi sağladı. İki kaynaktan toplam 844 kayıt başarıyla hedef tabloya aktarıldı.

7. Veri Kalitesi Raporu

ETL sürecinin üç aşaması karşılaştırıldığında ham veri ile temizlenmiş verinin aynı sayısal değerleri taşıdığı görülmektedir. NULL değerler 'Bilinmiyor' ile doldurulduğundan kayıt kaybı yaşanmamıştır.

Aşama	Toplam Kayıt	Eksik Şehir	Eksik Email	Eksik Telefon
STG_Musteri (Ham)	844	753	91	753
TEM_Musteri (Temizlenmiş)	844	753*	91*	753*
Hedef_Musteri (Final)	844	753*	91*	753*

8. Sonuç ve Değerlendirme

Bu projede Northwind ve AdventureWorks2022 veritabanlarından veri çekilerek kapsamlı bir ETL süreci başarıyla tasarlanmış ve uygulanmıştır.

Adım	Dosya	Yapılan İşlem	Sonuç
1	01_kaynak_veri_inceleme.sql	İki kaynaktan veri incelendi	Northwind 91, AW 753 satır
2	02_staging_tablosu_olustur.sql	Ham veri staging'e yüklendi	844 kayıt yüklendi
3	03_veri_kalitesi_analizi.sql	NULL ve format sorunları tespit edildi	753 eksik şehir, 91 eksik email
4	04_veri_temizleme.sql	Temizleme ve kalite skoru atandı	844 KISMI kayıt
5	05_adsoyad_format_duzeltme.sql	Title Case uygulandı	gustavo achong → Gustavo Achong
6	06_hedef_tabloya_yukle.sql	Temiz veri hedefe yüklendi	844 kayıt aktarıldı
7	07_etl_ozet_rapor.sql	3 aşama karşılaştırıldı	Kayıp yok, bütünlük sağlandı

ETL süreçlerinde en kritik nokta veri bütünlüğünün korunmasıdır. Bu projede NULL değerler anlamlı bir değerle ('Bilinmiyor') doldurularak kayıt kaybı önlenmiştir. İki farklı kaynaktan gelen verilerin birbirini tamamladığı gözlemlenmiştir. Northwind konum ve iletişim bilgisi, AdventureWorks ise email bilgisi sağlamıştır. Production ortamlarında bu iki kaynağın birleştirilerek tam müşteri profili oluşturulması önerilmektedir.